



---

**Machine Learning**

**Vector**

---

김선녕(ksycafe@gmail.com)

---



벡터

고윳값과 고유벡터

$$\vec{u} = (u_1, u_2, u_3), \quad \vec{v} = (v_1, v_2, v_3)$$

$$u + v = (u_1 + v_1, u_2 + v_2, u_3 + v_3)$$




$$u - v = (u_1 - v_1, u_2 - v_2, u_3 - v_3)$$

$$\alpha u = (\alpha u_1, \alpha u_2, \alpha u_3)$$

$$u \cdot v = (u_1 v_1 + u_2 v_2 + u_3 v_3)$$

$$u \times v = (u_2 v_3 - u_3 v_2, u_3 v_1 - u_1 v_3, u_1 v_2 - u_2 v_1)$$

$$\|u\| = \sqrt{u_1^2 + u_2^2 + u_3^2}$$



- 유클리디안 노름(Euclidean norm) :  $l_2$  노름.  $\|\cdot\|_2$  혹은  $\|\cdot\|$ 로 표시

$$\|\vec{v}\|_2 = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2} = \sqrt{\sum_{i=1}^n v_i^2}$$

- 맨해튼 노름(Manhattan Norm) :  $l_1$  노름.  $\|\cdot\|_1$ 로 표시

$$\|\vec{v}\|_1 = |v_1| + |v_2| + \cdots + |v_n| = \sum_{i=1}^n |v_i|$$

- 원소  $n$ 개인 벡터  $v$ 의  $l_p$  노름

$$\begin{aligned}\|\vec{v}\|_p &= \sqrt[p]{|v_0|^p + |v_1|^p + \cdots + |v_n|^p} = (|v_0|^p + |v_1|^p + \cdots + |v_n|^p)^{\frac{1}{p}} \\ &= \left( \sum_{i=1}^n |v_i|^p \right)^{\frac{1}{p}}\end{aligned}$$

- $l_0$  : 단순히 벡터에 있는 0이 아닌 원소의 수
  - $p = 1$  인 경우  $l_1$  노름,  $p = 2$  인 경우  $l_2$  노름
- 최대값 노름(Maximum Norm) :  $l_\infty$  노름. 벡터에서 가장 큰 절댓값  
 $\|\vec{v}\|_\infty = \max(|v_1|, |v_2|, \cdots, |v_n|)$


$$v = \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = \begin{bmatrix} 1 \\ -2 \\ 3 \end{bmatrix}$$

$$\|\vec{v}\|_2 = (|1|^2 + |-2|^2 + |3|^2)^{\frac{1}{2}} = \sqrt{14} \quad (p = 2 \text{ 일 때})$$

$$\|\vec{v}\|_2 = \sqrt{v_1^2 + v_2^2 + v_3^2} = \sqrt{1^2 + (-2)^2 + 3^2} = \sqrt{14}$$

$$\|\vec{v}\|_1 = |v_1| + |v_2| + |v_3| = |1| + |-2| + |3| = 6$$

$$\|\vec{v}\|_\infty = \max(|1|, |-2|, |3|) = 3$$



## 단위벡터(unit vector)

단위벡터 : 노름이 1인 벡터


벡터  $v$ 의 단위 벡터  $u = \frac{v}{\|v\|}$


(ex)

$$v = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$


$$\|v\| = \sqrt{1^2 + (2)^2 + 3^2} = \sqrt{14}$$

$$u = \frac{v}{\|v\|} = \begin{bmatrix} \frac{1}{\sqrt{14}} \\ \frac{2}{\sqrt{14}} \\ \frac{3}{\sqrt{14}} \end{bmatrix}$$






2차원 벡터



3차원 벡터



4차원 벡터(Iris 데이터)

$$\text{cosine similarity}(a, b) = \frac{a}{\|a\|} \cdot \frac{b}{\|b\|} = \cos(\theta)$$



$$u = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}, \quad v = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix}$$

$$u \cdot v = u^T \cdot v = [u_1 \quad u_2 \quad \cdots \quad u_n] \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} = u_1 v_1 + u_2 v_2 + \cdots + u_n v_n$$

$$v \cdot v = v^T \cdot v = \|v\|^2$$


$$v \cdot v = v^T \cdot v = [v_1 \quad v_2 \quad \cdots \quad v_n] \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} = v_1 v_1 + v_2 v_2 + \cdots + v_n v_n = \|v\|^2$$

- 벡터의 내적은 교환법칙 성립

$$v_1 \cdot v_2 = v_2 \cdot v_1$$

$$v_1^T \cdot v_2 = v_2^T \cdot v_1$$

$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = \begin{bmatrix} \alpha & 0 \\ 0 & \beta \end{bmatrix} \begin{bmatrix} x_1 \\ y_1 \end{bmatrix}, \quad \begin{aligned} x_2 &= \alpha x_1 \\ y_2 &= \beta y_1 \end{aligned}$$




$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} x_1 \\ y_1 \end{bmatrix}, \quad \begin{aligned} x_2 &= x_1 \cos \theta - y_1 \sin \theta \\ y_2 &= x_1 \sin \theta + y_1 \cos \theta \end{aligned}$$



- X축 기준으로 반사

$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ y_1 \end{bmatrix}, \quad \begin{aligned} x_2 &= x_1 \\ y_2 &= -y_1 \end{aligned} \quad A = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$



- Y축 기준으로 반사

$$B = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$$

- $x$ 축 방향으로  $y$ 의  $k$ 배만큼 충밀림

$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ y_1 \end{bmatrix}, \quad \begin{aligned} x_2 &= x_1 + ky_1 \\ y_2 &= y_1 \end{aligned}$$


$$A = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$$



- $y$ 축 방향으로  $x$ 의  $k$ 배만큼 충밀림

$$A = \begin{bmatrix} 1 & 0 \\ k & 1 \end{bmatrix}$$





$$\begin{cases} x_2 = x_1 + a \\ y_2 = y_1 + b \end{cases}$$

$$\begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ y_1 \end{bmatrix} + \begin{bmatrix} a \\ b \end{bmatrix}$$



# 벡터 고윳값과 고유벡터

벡터공간  $V$ 의 벡터  $v_1, v_2, \dots, v_n$ 에 대하여

$$c_1 v_1 + c_2 v_2 + \dots + c_n v_n = 0$$

를 만족하는 스칼라  $c_1, c_2, \dots, c_n$ 이  $c_1 = c_2 = \dots = c_n = 0$ 뿐일 때, 벡터  $v_1, v_2, \dots, v_n$ 은 **선형독립**이라 한다

벡터공간  $V$ 의 벡터  $v_1, v_2, \dots, v_n$ 이 선형독립이 아니면 **선형종속**이라 한다

- 선형독립(일차 독립)
  - 한 벡터를 스칼라배해서 다른 벡터를 만들 수 없다면 두 벡터는 일차독립
  - $n$ 개의 일차독립인 벡터를 선형결합하면  $n$ 차원 공간의 임의의 점을 나타낼 수 있다
- 선형종속(일차 종속)
  - 한 벡터를 스칼라배해서 다른 벡터를 만들 수 있을 때, 두 벡터는 일차종속
  - 일차 종속관계에 있는 벡터는 선형결합으로 오로지 직선밖에 만들지 못한다
- (ex)  $\mathbb{R}^3, v_1 = \{1, 2, 3\}, v_2 = \{-1, 0, 2\}, v_3 = \{0, 2, 4\}$   
(sol)  $c_1 v_1 + c_2 v_2 + c_3 v_3 = 0 \leftrightarrow (c_1 - c_2, 2c_1 + 2c_3, 3c_1 + 2c_2 + 4c_3) = (0, 0, 0)$   
 $c_1 = c_2 = c_3 = 0$ 으로 선형독립이다



$$\therefore [c_1 \quad c_2 \quad c_3] \begin{bmatrix} 1 & 2 & 3 \\ -1 & 0 & 2 \\ 0 & 2 & 4 \end{bmatrix}$$



정방행렬을 사용하여 선형변환할 때 크기는 변하더라도 방향이 변하지 않는 벡터를 **고유벡터**라 하고, 이때 크기 변화의 비율을 **고윳값**이라 한다.

$$Ax = \lambda x \leftrightarrow (A - \lambda I_n)x = 0, \quad (x \neq 0)$$

- $A$  :  $n$ 차 정방행렬
- $x$  : 고유벡터(*eigenvector*)
- $\lambda$  : 고윳값(*eigenvalue*)
- $\lambda x$  :  $x$ 의 상(*image*)



$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

- 행렬  $A$ 와 전치행렬  $A^T$ 의 고윳값은 동일하다

- 고유벡터의 선형독립
  - 행렬  $A \in \mathbb{R}^{n \times n}$ 의 서로 다른 고윳값  $\lambda_1, \lambda_2, \dots, \lambda_k$ 에 대응하는 고유벡터  $v_1, v_2, \dots, v_k$ 는 서로 선형독립이다
- 대칭행렬
  - 정사각행렬  $A$ 가  $A = A^T$ 를 만족하는 행렬  $A$
- 벡터의 수직
  - 두 벡터  $u, v \in \mathbb{R}^n$ 이  $u \cdot v = 0$ 을 만족하는 경우, 두 벡터  $u, v$ 는 서로 수직이다
- 대칭행렬의 고유벡터
  - $A \in \mathbb{R}^{n \times n}$ 이 대칭행렬일 때, 행렬  $A$ 의 서로 다른 고윳값에 대응하는 고유벡터는 서로 수직이다

$$A = \begin{bmatrix} 2 & 3 \\ 3 & -6 \end{bmatrix}$$

$$\lambda I - A = \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 2 & 3 \\ 3 & -6 \end{bmatrix} = \begin{bmatrix} \lambda - 2 & -3 \\ -3 & \lambda + 6 \end{bmatrix}$$

$$\begin{aligned} \det(\lambda I - A) = \begin{bmatrix} \lambda - 2 & -3 \\ -3 & \lambda + 6 \end{bmatrix} = 0 &\Rightarrow (\lambda - 2)(\lambda + 6) - 9 = 0 \\ &\Rightarrow \lambda^2 + 4\lambda - 21 = (\lambda - 3)(\lambda + 7) = 0 \\ &\Rightarrow \lambda = 3, -7 \quad (\text{고윳값}) \end{aligned}$$

①  $\lambda_1 = 3$ 일 때,


$$3I - A = \begin{bmatrix} 1 & -3 \\ -3 & 9 \end{bmatrix} \text{이므로, } (3I - A)x = 0 \text{ 에서 고유벡터는 } \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

②  $\lambda_2 = -7$ 일 때,

$$-7I - A = \begin{bmatrix} -9 & -3 \\ -3 & -1 \end{bmatrix} \text{이므로, } (-7I - A)x = 0 \text{ 에서 고유벡터는 } \begin{bmatrix} 1 \\ -3 \end{bmatrix}$$

## 사영(projection)

- 벡터  $b$ 를 벡터  $a$ 에 사영한 결과  $x$



- 벡터  $b$ 를 빗변으로 하는 직각 삼각형의 밑변이 벡터  $x$ 이면 높이는  $\vec{b} - \vec{a}$
- 직교벡터의 내적은 0

$$(\vec{b} - \vec{a})^T \vec{a} = 0$$

$$(\vec{b} - p\vec{a})^T \vec{a} = 0$$

$$\vec{b}^T \vec{a} - p\vec{a}^T \vec{a} = 0$$

$$p = \frac{\vec{b}^T \vec{a}}{\vec{a}^T \vec{a}}$$

$a$ 가 유닛벡터( $\vec{a}^T \vec{a} = 1$ )이면  $p$ 는  $\vec{b}^T \vec{a}$ , 벡터  $a$ 와  $b$ 의 내적만으로도 구할 수 있다

공분산 : 두 측정값 사이에 연관성을 분석

$n$ 차원의 데이터  $X = \{x_1, x_2, \dots, x_n\}$ 에 대한 평균벡터와 공분산 행렬

$m$  : 평균벡터(*mean vector*),  $n$ 차원 벡터

$C$  : 공분산 행렬(*covariance matrix*),  $n \times n$ 행렬

$$m = \frac{1}{k} \sum_{i=1}^k x_i \quad C = \frac{1}{k} \sum_{i=1}^k (x_i - m)^T (x_i - m)$$

$$X^T X = \begin{bmatrix} - & x_1 & - \\ - & x_2 & - \\ \dots & & \\ - & x_k & - \end{bmatrix} \begin{bmatrix} | & | & \dots & | \\ x_1 & x_2 & \dots & x_k \\ | & | & & | \end{bmatrix} = \begin{bmatrix} cov(x_1, x_1) & cov(x_1, x_2) & \dots & cov(x_1, x_k) \\ cov(x_2, x_1) & cov(x_2, x_2) & \dots & cov(x_2, x_k) \\ \vdots & \vdots & \ddots & \vdots \\ cov(x_k, x_1) & cov(x_k, x_2) & \dots & cov(x_k, x_k) \end{bmatrix}$$

$$\frac{X^T X}{k} = \frac{1}{k} \begin{bmatrix} cov(x_1, x_1) & cov(x_1, x_2) & \dots & cov(x_1, x_k) \\ cov(x_2, x_1) & cov(x_2, x_2) & \dots & cov(x_2, x_k) \\ \vdots & \vdots & \ddots & \vdots \\ cov(x_k, x_1) & cov(x_k, x_2) & \dots & cov(x_k, x_k) \end{bmatrix}$$

$$x_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad x_w = \begin{bmatrix} 2 \\ 3 \end{bmatrix}, \quad x_3 = \begin{bmatrix} 4 \\ 1 \end{bmatrix}, \quad x_4 = \begin{bmatrix} 4 \\ 5 \end{bmatrix}$$

$$m = \frac{1}{k} \sum_{i=1}^k x_i = \frac{1}{4} \left( \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 2 \\ 3 \end{bmatrix} + \begin{bmatrix} 4 \\ 1 \end{bmatrix} + \begin{bmatrix} 4 \\ 5 \end{bmatrix} \right) = \begin{bmatrix} 3 \\ 2.5 \end{bmatrix}$$

$$\begin{aligned} C &= \frac{1}{k} \sum_{i=1}^k (x_i - m) (x_i - m)^T \\ &= \frac{1}{4} \left( \begin{bmatrix} -1 \\ -1.5 \end{bmatrix} \begin{bmatrix} -1 & -1.5 \end{bmatrix} + \begin{bmatrix} -1 \\ 0.5 \end{bmatrix} \begin{bmatrix} -1 & 0.5 \end{bmatrix} + \begin{bmatrix} 1 \\ -1.5 \end{bmatrix} \begin{bmatrix} 1 & -1.5 \end{bmatrix} + \begin{bmatrix} 1 \\ 2.5 \end{bmatrix} \begin{bmatrix} 1 & 2.5 \end{bmatrix} \right) \\ &= \frac{1}{4} \left( \begin{bmatrix} 1 & 1.5 \\ 1.5 & 2.25 \end{bmatrix} + \begin{bmatrix} 1 & -0.5 \\ -0.5 & 0.25 \end{bmatrix} + \begin{bmatrix} 1 & -1.5 \\ -1.5 & 2.25 \end{bmatrix} + \begin{bmatrix} 1 & 2.5 \\ 2.5 & 6.25 \end{bmatrix} \right) \\ &= \frac{1}{4} \begin{bmatrix} 4 & 2 \\ 2 & 11 \end{bmatrix} = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 2.75 \end{bmatrix} \end{aligned}$$



$$x_i \leftarrow x_i - m$$

변환된 데이터

$$x_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix} - \begin{bmatrix} 3 \\ 2.5 \end{bmatrix} = \begin{bmatrix} -1 \\ -1.5 \end{bmatrix} \quad x_2 = \begin{bmatrix} 2 \\ 3 \end{bmatrix} - \begin{bmatrix} 3 \\ 2.5 \end{bmatrix} = \begin{bmatrix} -1 \\ -0.5 \end{bmatrix}$$


$$x_3 = \begin{bmatrix} 4 \\ 1 \end{bmatrix} - \begin{bmatrix} 3 \\ 2.5 \end{bmatrix} = \begin{bmatrix} 1 \\ -1.5 \end{bmatrix} \quad x_4 = \begin{bmatrix} 4 \\ 5 \end{bmatrix} - \begin{bmatrix} 3 \\ 2.5 \end{bmatrix} = \begin{bmatrix} 1 \\ 2.5 \end{bmatrix}$$

변환된 데이터의 평균벡터: 영벡터  $\frac{1}{4} \left( \begin{bmatrix} -1 \\ -1.5 \end{bmatrix} + \begin{bmatrix} -1 \\ -0.5 \end{bmatrix} + \begin{bmatrix} 1 \\ -1.5 \end{bmatrix} + \begin{bmatrix} 1 \\ 2.5 \end{bmatrix} \right) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$




- 차원을 줄이면 정보손실(information loss) 발생
- 따라서 차원 축소시에는 정보 손실 최소화


2차원 데이터의 1차원 데이터로의 차원축소의 예



$$u = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \text{에 사영}$$



$$u = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \text{에 사영}$$



$$u = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} \text{에 사영}$$



$$x_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix} - \begin{bmatrix} 3 \\ 2.5 \end{bmatrix} = \begin{bmatrix} -1 \\ -1.5 \end{bmatrix} \quad x_2 = \begin{bmatrix} 2 \\ 3 \end{bmatrix} - \begin{bmatrix} 3 \\ 2.5 \end{bmatrix} = \begin{bmatrix} -1 \\ -0.5 \end{bmatrix}$$

$$x_3 = \begin{bmatrix} 4 \\ 1 \end{bmatrix} - \begin{bmatrix} 3 \\ 2.5 \end{bmatrix} = \begin{bmatrix} 1 \\ -1.5 \end{bmatrix} \quad x_4 = \begin{bmatrix} 4 \\ 5 \end{bmatrix} - \begin{bmatrix} 3 \\ 2.5 \end{bmatrix} = \begin{bmatrix} 1 \\ 2.5 \end{bmatrix}$$

1.  $u = [1 \ 0]^T$ ,      평균분산 = **1.0**

$$[1 \ 0] \begin{bmatrix} -1 \\ -1.5 \end{bmatrix} = -1, [1 \ 0] \begin{bmatrix} -1 \\ -0.5 \end{bmatrix} = -1, [1 \ 0] \begin{bmatrix} 1 \\ -1.5 \end{bmatrix} = 1, [1 \ 0] \begin{bmatrix} 1 \\ 2.5 \end{bmatrix} = 1$$

2.  $u = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}^T$ ,      평균분산 = **1.22**

$$\begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} -1 \\ -1.5 \end{bmatrix} = -\frac{2.5}{\sqrt{2}}, \quad \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} -1 \\ -0.5 \end{bmatrix} = -\frac{1.5}{\sqrt{2}}$$

$$\begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 1 \\ -1.5 \end{bmatrix} = -\frac{0.5}{\sqrt{2}}, \quad \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 1 \\ 2.5 \end{bmatrix} = -\frac{3.5}{\sqrt{2}}$$

- $n$ 차원 데이터  $\{x_1, x_2, \dots, x_m\}$ 을 새로운 기저  $\{u_1, u_2, \dots, u_n\}$ 의 좌표계로 선형변환할 때, 임의의  $n$ 차원 데이터  $x$  ( $u$ 에서  $x^T u$ 만큼의 거리)

$$x = \sum_{i=1}^n (x^T u_i) u_i \quad (x^T u_i = x \cdot u_i \text{는 } x \text{를 } u_i \text{ 방향으로 정사영한 벡터의 크기})$$

$$n\text{차원 좌표계에서 } K\text{개의 기저벡터로 } x \text{를 근사} : \hat{x} = \sum_{i=1}^K (x^T u_i) u_i$$

$$\begin{aligned} J(\text{오차}) &= \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2 = \frac{1}{n} \sum_{i=1}^n \left( \sum_{j=1}^n (x_i^T u_j) u_j - \sum_{j=1}^K (x_i^T u_j) u_j \right)^2 \\ &= \frac{1}{n} \sum_{i=1}^n \left( \sum_{j=K+1}^n (x_i^T u_j) u_j \right)^2 = \frac{1}{n} \sum_{i=1}^n \sum_{j=K+1}^n (x_i^T u_j)^2 \quad (v^T v = v^2) \\ &= \frac{1}{n} \sum_{i=1}^n \sum_{j=K+1}^n (x_i^T u_j)^T (x_i^T u_j) = \frac{1}{n} \sum_{i=1}^n \sum_{j=K+1}^n u_j^T x_i x_i^T u_j \\ &= \sum_{j=K+1}^n u_j^T \left( \frac{1}{n} \sum_{i=1}^n x_i x_i^T \right) u_j \\ &= \sum_{j=K+1}^n u_j^T C u_j \quad \left( \text{평균벡터가 영벡터이므로 } \frac{1}{n} \sum_{i=1}^n x_i x_i^T = C \right) \end{aligned}$$

$$u_j^T C u_j = u_j^T \left( \frac{1}{n} \sum_{i=1}^n x_i x_i^T \right) u_j = \frac{1}{n} \sum_{i=1}^n u_j^T x_i x_i^T u_j = \frac{1}{n} \sum_{i=1}^n (x_i^T u_j)^T (x_i^T u_j) = \sigma_j^2$$

분산( $u_j^T C u_j = \sigma_j^2$ )을 가장 크게 하는 기저벡터  $u$ 를 찾는 최적화 문제  
(제한조건 :  $u^T u = 1$ )

라그랑주 승수  $\lambda$ 를 사용하여 목적함수  $\mathcal{L}$  정의

$$\mathcal{L} = u^T C u - \lambda(u^T u - 1)$$

$$\frac{\delta \mathcal{L}}{\delta u^T} = C u - \lambda u = 0 \quad \Rightarrow \quad C u = \lambda u$$

( $u$ 는 공분산 행렬  $C$ 의 고유벡터,  $\lambda$ 는 고윳값)

$$u^T C u = \lambda u^T u = \lambda = \sigma^2$$

데이터의 공분산 행렬  $C$ 로 부터 고윳값( $\lambda$ )이 큰 순서대로  $K$ 의 고유벡터  $\{u_1, u_2, \dots, u_K\}$ 를 선택

$$\{u_1, u_2, \dots, u_K\} \quad (\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_K)$$

이때 선택된 축을 주성분 축(*principal axis*) 혹은 주성분 벡터(*principal vector*)라 한다.

$$x_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \quad x_2 = \begin{bmatrix} 2 \\ 3 \end{bmatrix} \quad x_3 = \begin{bmatrix} 4 \\ 1 \end{bmatrix} \quad x_4 = \begin{bmatrix} 4 \\ 5 \end{bmatrix}$$

$$m = \begin{bmatrix} 3 \\ 2.5 \end{bmatrix} \quad C = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 2.75 \end{bmatrix}$$

$$\lambda_1 = \frac{15 + \sqrt{65}}{8}, \quad u_1 = \begin{bmatrix} \frac{\sqrt{65} - 7}{4} \\ 1 \end{bmatrix} \approx \begin{bmatrix} 0.27 \\ 1 \end{bmatrix}$$

$$\lambda_2 = \frac{15 - \sqrt{65}}{8}, \quad u_2 = \begin{bmatrix} \frac{\sqrt{65} + 7}{4} \\ 1 \end{bmatrix} \approx \begin{bmatrix} -3.77 \\ 1 \end{bmatrix}$$

$\lambda_1 > \lambda_2$  이므로  $u_1$  사용

$$\hat{x}_1 \approx x_1^T u_1 = [2 \quad 1] \begin{bmatrix} 0.27 \\ 1 \end{bmatrix} = 1.54$$

$$\hat{x}_2 \approx x_2^T u_1 = [2 \quad 3] \begin{bmatrix} 0.27 \\ 1 \end{bmatrix} = 3.54$$

$$\hat{x}_3 \approx x_3^T u_1 = [4 \quad 1] \begin{bmatrix} 0.27 \\ 1 \end{bmatrix} = 2.08$$

$$\hat{x}_4 \approx x_4^T u_1 = [4 \quad 5] \begin{bmatrix} 0.27 \\ 1 \end{bmatrix} = 6.08$$

- $m \times n$  실수행렬  $A$ 의 특잇값은  $A^T A$ 에 대한 고윳값의 양의 제곱근이다. 즉,  $A$ 의 특잇값  $\sigma_i$ 는  $A^T A$ 에 대한 고윳값  $\lambda_i$ 의 양의 제곱근  $\sqrt{\lambda_i}$ 이다.

[예]  $A = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix}$ 의 특이값은?

$$A^T A = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix} = \begin{bmatrix} 10 & 0 & 2 \\ 0 & 10 & 4 \\ 2 & 4 & 2 \end{bmatrix}$$

$$\det(\lambda I - A^T A) = \lambda(\lambda - 10)(\lambda - 12) = 0$$

$$A^T A \text{의 고윳값} : \lambda_1 = 12, \quad \lambda_2 = 10, \quad \lambda_3 = 0$$

$$A \text{의 특잇값} : \sigma_1 = 2\sqrt{3}, \quad \sigma_2 = \sqrt{10}, \quad \sigma_3 = 0$$

# 특잇값 분해(Singular Value Decomposition)

- $m \times n$  실수행렬  $A$ 를  $A = U\Sigma V^T$ 로 표현한 것을 **특잇값 분해(SVD)**라고 한다. 이때  $U$ 는  $m \times m$  직교행렬,  $V$ 는  $n \times n$  직교행렬,  $\Sigma$ 는 주대각 성분에  $A$ 의 특잇값을 큰 것부터 차례대로 넣은  $m \times n$  직사각 대각행렬이다
  - 직사각 대각행렬 (*rectangular diagonal matrix*): 주대각 성분에 특잇값이 위치하고 나머지 성분은 모두 0인 직사각행렬( $\Sigma$ )

$$A = U\Sigma V^T$$

↓

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 2 \\ 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 4 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & -1 \\ 1 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 4 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & \sqrt{5} & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ \sqrt{0.2} & 0 & 0 & 0 & \sqrt{0.8} \\ 0 & 0 & 0 & 1 & 0 \\ -\sqrt{0.8} & 0 & 0 & 0 & \sqrt{0.2} \end{bmatrix}$$

$U$ 는  $4 \times 4$  직교행렬

$\Sigma$ 는  $A$ 의 특잇값을 주대각 성분으로 갖는  $4 \times 5$  직사각 대각행렬

$V$ 는  $5 \times 5$  직교행렬.

$$A = U\Sigma V^T = \sum_{i=1}^r \sigma_i u_i v_i^T \quad (r \text{은 } A \text{의 계수. 특잇값 개수})$$

$$\begin{bmatrix} \vdots & \vdots & \cdots & \vdots \\ u_1 & u_2 & \cdots & u_m \\ \vdots & \vdots & & \vdots \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 & \cdots & 0 \\ & \ddots & & \vdots & \ddots & \vdots \\ & & \sigma_r & 0 & \cdots & 0 \\ 0 & \cdots & 0 & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} \cdots & v_1 & \cdots \\ \cdots & v_2 & \cdots \\ \vdots & & \\ \cdots & v_n & \cdots \end{bmatrix}$$
$$= \sigma_1 u_1 v_1^T + \cdots + \sigma_r u_r v_r^T + 0 + \cdots + 0$$

$$X = U\Sigma V^T$$

평균벡터가 영벡터라 가정하면 공분산 행렬  $C$ 는

$$\begin{aligned} C &= \frac{1}{m-1} X^T X = \frac{1}{m-1} (U\Sigma V^T)^T U\Sigma V^T \\ &= \frac{1}{m-1} V\Sigma^T U^T U\Sigma V^T \\ &= \frac{1}{m-1} V\Sigma^T \Sigma V^T \\ &= VSV^T \quad \left( S = \frac{1}{m-1} \Sigma^T \Sigma \right) \end{aligned}$$

따라서  $C = VSV^T$ 는  $C$ 의 고윳값 분해에 해당.

그러므로  $C$ 의 고유벡터인  $V$ 의 열벡터는 주성분 벡터이고  $V$ 의 고윳값  $\lambda_i$ 는 특이값  $\sigma_i$ 에 대해  $\lambda_i = \sigma_i^2 / (m-1)$ 이다.

$X = U\Sigma V^T$ 에서  $V$ 의 각 열벡터는 주성분 벡터. 주성분 분석에서  $V$ 에서 왼쪽에 있는  $k$ 개의 열벡터를 주성분 벡터로 사용

차원축소 :  $xV_k$  ( $V_k$ 는  $V$ 의 왼쪽  $k$ 개의 열벡터)



$$x_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \quad x_2 = \begin{bmatrix} 2 \\ 3 \end{bmatrix} \quad x_3 = \begin{bmatrix} 4 \\ 1 \end{bmatrix} \quad x_4 = \begin{bmatrix} 4 \\ 5 \end{bmatrix}$$

$X'$  : 평균벡터( $m$ )가 영벡터가 되도록 각 데이터에서 평균벡터를 뺀 행렬

$$X = \begin{bmatrix} 2 & 1 \\ 2 & 3 \\ 4 & 1 \\ 4 & 5 \end{bmatrix} \quad m = [3 \quad 2.5] \quad X' = \begin{bmatrix} -1 & -1.5 \\ -1 & 0.5 \\ 1 & -1.5 \\ 1 & 2.5 \end{bmatrix}$$

특이값 분해

$$U \approx \begin{bmatrix} -0.50 & -0.31 & 0.08 & 0.80 \\ 0.07 & -0.59 & 0.76 & -0.26 \\ -0.35 & 0.73 & 0.59 & 0.01 \\ 0.79 & 0.17 & 0.25 & 0.54 \end{bmatrix} \quad \Sigma \approx \begin{bmatrix} 3.40 & 0 \\ 0 & 1.86 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \quad V \approx \begin{bmatrix} 0.26 & 0.97 \\ 0.97 & -0.26 \end{bmatrix}$$

$V$ 의 첫 번째 열벡터를 주성분 벡터  $v$ 로 선택 :  $v = \begin{bmatrix} 0.26 \\ 0.97 \end{bmatrix}$

$$\hat{x}_1 \approx x_1^T v = [2 \quad 1] \begin{bmatrix} 0.26 \\ 0.97 \end{bmatrix} = 1.49 \quad \hat{x}_2 \approx x_2^T v = [2 \quad 3] \begin{bmatrix} 0.26 \\ 0.97 \end{bmatrix} = 3.43$$

$$\hat{x}_3 \approx x_3^T v = [4 \quad 1] \begin{bmatrix} 0.26 \\ 0.97 \end{bmatrix} = 2.01 \quad \hat{x}_4 \approx x_4^T v = [4 \quad 5] \begin{bmatrix} 0.26 \\ 0.97 \end{bmatrix} = 5.89$$